

Projet de Groupe : Température Terrestre

Introduction

Le réchauffement climatique est aujourd'hui l'un des défis majeurs auxquels l'humanité est confrontée. Les phénomènes extrêmes, comme les vagues de chaleur, les tempêtes violentes, la montée du niveau des mers ou encore la fonte des glaciers, sont autant de manifestations inquiétantes d'un climat qui se dérègle. Comprendre ces changements est essentiel pour anticiper leurs impacts sur l'environnement, les écosystèmes, et les sociétés humaines.

Depuis la révolution industrielle, les activités humaines ont profondément modifié l'atmosphère terrestre. Les émissions de dioxyde de carbone (CO₂), de méthane (CH₄) et d'autres gaz à effet de serre ont considérablement augmenté, contribuant au phénomène d'effet de serre amplifié. Pourtant, pour évaluer précisément l'ampleur de ces transformations et les relier aux activités humaines, il est crucial d'analyser les données climatiques sur une longue période.

Ce projet s'inscrit dans cette démarche en examinant l'évolution des températures terrestres depuis 1880, une date clé marquant le début des relevés météorologiques systématiques et suffisamment fiables pour identifier des tendances significatives. En croisant ces données avec celles des émissions de CO₂ et des gaz à effet de serre, nous chercherons à établir des corrélations et à identifier les régions les plus impactées ou impactantes dans ce processus global. En fonction des résultats obtenus, nous approfondirons l'analyse pour une région spécifique, comme l'Europe. Cette approche permettra d'examiner les facteurs responsables de son impact climatique et d'évaluer les solutions mises en place pour réduire son empreinte carbone.

1. Contexte et enjeux :

- Brève présentation du réchauffement climatique.

Depuis près d'un siècle et demi, la Terre connaît une hausse progressive de sa température moyenne. Ce phénomène, souvent appelé "réchauffement climatique", est attribué en grande partie à l'activité humaine, notamment la combustion des énergies fossiles, la déforestation, et l'agriculture intensive. Les effets de ce réchauffement sont multiples : des changements dans les régimes climatiques, une augmentation de la fréquence des événements climatiques extrêmes, et des impacts sur les écosystèmes naturels. Ces bouleversements, à la fois environnementaux et sociétaux, soulèvent des questions cruciales sur l'avenir de notre planète et sur les solutions nécessaires pour limiter les dégâts.

- Importance d'étudier les données climatiques depuis 1880.

L'année 1880 marque le début de relevés systématiques des températures globales, permettant de construire une base de données fiable et cohérente. Étudier cette période offre plusieurs avantages :

1. **Identifier les tendances climatiques sur le long terme** : En analysant des données sur plus de 140 ans, il est possible de discerner des variations naturelles des températures (comme les cycles climatiques) des tendances induites par les activités humaines.
2. **Relier les évolutions climatiques aux activités humaines** : Le XIXe siècle coïncide avec l'essor de l'industrialisation et de l'usage massif des énergies fossiles. Les données permettent de corréliser l'augmentation des émissions de gaz à effet de serre avec l'évolution des températures.
3. **Prévoir les impacts futurs** : Comprendre les changements passés est essentiel pour modéliser et anticiper l'évolution du climat dans les décennies à venir, et pour informer les hommes politiques des solutions de réduction des émissions.

En somme, l'étude des données climatiques depuis 1880 constitue une clé de compréhension majeure des dynamiques climatiques actuelles et de leur impact sur notre planète. Cela permet non seulement d'identifier les causes du réchauffement, mais aussi d'éclairer les mesures nécessaires pour le limiter.

2. Objectifs du projet :

- Quels sont les principaux objectifs à atteindre ? Décrivez en quelques lignes:
- Les principaux objectifs à atteindre sont :
 - Identifier l'évolution des températures terrestres depuis 1880, en mettant en évidence les tendances globales et régionales.
 - Étudier les liens entre les émissions de gaz à effet de serre, notamment le CO₂, Méthane et N₂O et le réchauffement climatique, afin de comprendre leur contribution au phénomène.
 - Localiser les zones les plus impactées ou impactantes par ces évolutions, et approfondir l'analyse sur une région spécifique, comme l'Europe. Cela permettra d'évaluer les causes de son impact climatique et d'examiner les solutions mises en place pour réduire son empreinte.
- Pour chacun des membres du groupe, préciser le niveau d'expertise autour de la problématique adressée ?

Dalia : J'ai une bonne compréhension des bases scientifiques liées au réchauffement climatique. Je suis en phase d'apprentissage dans l'analyse de données environnementales avec des outils comme Matplotlib et Seaborn, ce qui me permet de créer des visualisations pertinentes pour explorer la problématique.


David : Aucune expérience pour ma part / un intérêt pour la cause environnementale et le monde de la Data !

Laure : Pas d'expérience spécifique sur le sujet des températures terrestres, une bonne expérience de la data et un intérêt pour ce sujet, pour essayer de comprendre quelles tentatives pourraient changer la situation actuelle d'augmentation des températures.

Partie I : Évolution des températures terrestres

1. Évolution globale des températures :

- a. Graphique : Évolution annuelle de la température mondiale (moyenne annuelle).




b. Analyse des tendances observées.

On observe une tendance générale à la hausse des températures mondiales au fil du temps, particulièrement marquée à partir des années 1980.

Les années les plus récentes (après 2000) montrent une augmentation accélérée, avec des températures atteignant plus de 1 °C au-dessus de la moyenne de référence.

Cette augmentation est un indicateur clair du réchauffement climatique.

c. Graphique : Températures mondiales par saison et par année (moyennes saisonnières).



d. Identification des variations saisonnières.

Il y a une augmentation significative des températures moyennes au fil du temps, notamment après les années 1980, signe du réchauffement climatique.

Chaque saison suit une tendance similaire d'augmentation, bien que les variations saisonnières soient légèrement différentes.


Les fluctuations d'une année à l'autre montrent une variabilité saisonnière normale, mais la tendance à long terme est clairement orientée à la hausse.

Ce graphique illustre clairement une tendance au réchauffement climatique global, affectant toutes les saisons de manière relativement cohérente, mais avec des variations interannuelles.

2. Comparaison par hémisphère :

a. Graphiques :


i. Températures de l'Hémisphère Nord (annuelle et saisonnière).



Une augmentation progressive de la température est visible.

La hausse s'accélère particulièrement à partir des années 1980.

Les anomalies positives deviennent beaucoup plus fréquentes et prononcées dans les décennies récentes, culminant autour de 2020.




Une augmentation des températures saisonnières est visible, particulièrement marquée après 1980.

Les anomalies positives deviennent plus fréquentes et intenses au fil des années, suggérant un réchauffement climatique.

L'hiver semble présenter une variabilité plus importante que les autres saisons, avec des oscillations prononcées.

Les tendances à la hausse sont visibles pour toutes les saisons, mais l'été et l'hiver montrent des augmentations particulièrement marquées.

ii. Températures de l'Hémisphère Sud (annuelle et saisonnière).




On observe une augmentation globale des températures au fil du temps

Bien que la tendance soit à la hausse, des variations interannuelles sont visibles, avec des périodes de baisse suivies de hausses significatives.

L'augmentation des températures semble s'accroître particulièrement à partir des années 1970, avec une croissance plus marquée depuis les années 2000.

Les températures étaient souvent en dessous de la moyenne au début de la période (1880–1940), mais elles ont franchi des sommets inédits au cours des deux dernières décennies.



Une hausse progressive des températures est visible à travers toutes les saisons, particulièrement marquée à partir des années 1970-1980.


Il existe des fluctuations importantes dans les températures d'une année à l'autre, surtout au début de la période étudiée.

Ces fluctuations sont plus atténuées vers la fin de la période, où la hausse des températures semble plus constante.

Les courbes des différentes saisons sont globalement similaires, indiquant que l'impact du réchauffement climatique est homogène dans cet hémisphère.

b. Graphique : Comparaison des températures entre hémisphères.

Zonal annual means, 1880-present / Tendance des températures par hémisphère



c. Discussion des différences observées.


Le graphique des tendances des températures par hémisphère montre que l'hémisphère nord et l'hémisphère sud ont des trajectoires différentes en termes de réchauffement.

Une tendance plus marquée de réchauffement dans l'hémisphère nord par rapport à l'hémisphère sud, peut être liée à une plus grande proportion de terres émergées, qui se réchauffent plus rapidement que les océans.

L'augmentation des températures dans l'hémisphère sud reste plus modérée, probablement en raison de la dominance des océans qui absorbent et distribuent la chaleur.

3. Analyse par zones de latitude :

a. Graphique : Évolution de la température par zone de latitude.



b. Impact du réchauffement climatique selon les régions géographiques.

64N-90N (Arctique) : on assiste à un réchauffement rapide et extrême, fonte des glaces et réduction de l'albédo, augmentant l'absorption de chaleur par la Terre, ce qui entraîne une accélération des phénomènes de fonte et d'augmentation des températures.

44N-64N : Cette région, comprenant une grande partie de l'Europe et de l'Amérique du Nord, montre également un réchauffement significatif.

24N-44N : Inclut des régions comme le sud de l'Europe, l'Asie centrale, et le sud des États-Unis. On observe une augmentation notable des températures, avec des implications pour l'agriculture et l'approvisionnement en eau.

EQU-24N et 24S-EQU (Zone Équatoriale) : La bande équatoriale montre une variabilité plus faible, mais une tendance au réchauffement constant.

44S-24S et 64S-44S : Ces zones de l'hémisphère sud montrent des réchauffements moins intenses mais présents.


90S-64S (Antarctique) : Les tendances de réchauffement sont visibles, avec des impacts potentiels sur les calottes glaciaires et le niveau de la mer.

Les résultats montrent un réchauffement significatif et global, avec des impacts particulièrement sévères dans les régions polaires et à haute latitude. Les zones équatoriales, bien que montrant une variabilité moindre, subissent également des changements constants.

Partie II : Causes du réchauffement climatique

1. Émissions de gaz à effet de serre :

- Répartition des émissions de GES par type de gaz et par région.
- Impact cumulé des émissions depuis 1880.




La Chine est largement en tête avec les émissions les plus élevées, Suivie des États-Unis en deuxième position. L'Inde complète le podium en troisième position. La Russie arrive en quatrième position et Le Japon est cinquième

- Il y a un écart très important entre les premiers pays (Chine, États-Unis) et le reste du classement
- Les pays industrialisés et les économies émergentes dominent le classement
- La majorité des émissions sont sous forme de CO2
- Les émissions de méthane et d'oxyde nitreux sont présentes mais en quantités plus

faibles

- L'Asie est fortement représentée (Chine, Inde, Japon, Corée du Sud...)
- Plusieurs pays européens figurent dans le classement (Allemagne, France, Royaume-Uni...)
- Présence importante de pays producteurs de pétrole (Arabie Saoudite, Iran, Russie...)



L'Asie se démarque largement avec des émissions totales les plus élevées, principalement en CO₂. Cela reflète une population importante, une industrialisation rapide, et une dépendance encore marquée aux énergies fossiles.


L'Amérique du Nord est le deuxième plus grand émetteur, avec des contributions significatives en CO₂ mais également des émissions notables de méthane.

L'Europe arrive ensuite, avec des émissions globalement plus faibles grâce à des politiques environnementales plus strictes.

Afrique et Amérique du Sud : Ces continents ont des émissions relativement modestes mais présentent une part non négligeable de méthane et d'oxyde nitreux, souvent liés à l'agriculture et à la déforestation.



2. Émissions de CO2 :

- Corrélation entre l'augmentation de la température terrestre et des émissions de CO2 :



Le Coefficient de corrélation CO2 / Températures Globales est de 0.9325.

L'augmentation des émissions de CO2 semble intimement liée à la hausse des températures globales, on peut ainsi penser que les activités humaines jouent un rôle dans le réchauffement climatique.




On observe une augmentation des émissions de CO2 à partir de 1850 et une augmentation significative à partir de 1950.

Il semble y avoir une corrélation entre l'activité humaine et cette augmentation des émissions de CO2 : en effet, dans le zoom à droite, autour de 2020, on remarque que lors de la crise de la COVID, les activités humaines cessent, les émissions de CO2 baissent.

- Graphiques :

- Distribution des émissions de CO2 dans le monde par année.
- Émissions de CO2 par continent, population et PIB etc.




Les 3 principaux émetteurs de CO2 sont la **Chine, les Etats Unis et l'Inde**. La Chine émet plus que les deux suivants réunis.

Les plus gros émetteurs sont en Asie, en Amérique du Nord et en Europe mais **certains pays du Golfe** sont eux aussi concernés sans doute à cause de la production de pétrole.

Certains pays d'Asie en développement combinent industrialisation rapide et croissance Économique (**Inde, l'Indonésie, le Brésil, et le Vietnam**)

Il est également important de noter l'impact des énergies fossiles qui accentuent les Émissions **chinoises indiennes et américaines**




La majorité des pays les moins émetteurs sont des petits États insulaires ou des territoires ayant des populations déduites et pas d'industries lourdes.

Partie III : Impact géographique et sociétal en Europe

1. Zones les plus impactées :


- Analyse des températures et des événements extrêmes (sécheresses, etc.).
- Analyse des émissions de CO2 par secteur, régions, pays.



L'Allemagne se distingue comme le pays européen émettant le plus de CO₂, suivie de l'Italie, du Royaume-Uni et de la Pologne. Ces pays sont généralement caractérisés par une population importante et une activité industrielle significative. Des pays comme la France, l'Espagne, et l'Ukraine occupent des positions intermédiaires en termes d'émissions, reflétant des économies industrielles et des politiques climatiques variées.

2. Part de responsabilité et conséquences potentielles :

- Comparaison avec d'autres régions et conséquences climatiques



Coefficient de corrélation entre le co2 et le gdp (PIB) : 0.800761

- La ligne rouge indique une corrélation positive entre le PIB et les émissions de CO₂ : en général, plus le PIB d'un pays est élevé, plus ses émissions de CO₂ sont importantes.
- Cette tendance suggère que le développement économique (reflété par le PIB) est historiquement lié à une augmentation des émissions de gaz à effet de serre.
- La pente de la ligne de régression montre que l'effet n'est pas constant. L'incertitude (zone en rouge clair autour de la ligne) augmente avec le PIB, ce qui signifie qu'il y a davantage de variabilité dans les émissions pour les pays ayant un PIB élevé.

Pays à faible PIB :

- À gauche du graphique (PIB faible, proche de 0), les points sont concentrés et montrent des émissions de CO₂ faibles à modérées. Cela correspond probablement à des pays européens avec des économies en développement ou des années plus anciennes (années 1950 à 1970).


Pays à haut PIB :

- À droite du graphique (PIB élevé, supérieur à $1e12$), on observe une plus grande dispersion des émissions. Certains pays affichent des émissions très élevées (au-delà de 1000) tandis que d'autres restent relativement modérées malgré leur PIB important. Cela peut refléter :
 - Une transition vers des technologies plus propres.
 - Des différences dans les politiques climatiques et l'efficacité énergétique entre les pays.

Exceptions ou anomalies :

- Quelques points se trouvent très au-dessus de la ligne de tendance. Ces pays/années ont des émissions de CO₂ particulièrement élevées pour leur PIB. Cela pourrait être dû à une dépendance importante aux combustibles fossiles ou à une industrialisation rapide.

Les précurseurs en Europe : Emission de CO2 des 6 pays fondateurs de EU en 2023




L'Allemagne montre des émissions de CO₂ beaucoup plus élevées que les autres pays, ce qui semble indiquer une plus grande dépendance aux sources d'énergie fossiles ou un secteur industriel plus développé.


Zoom sur la France et les pays les plus proches de la France en Populations et

PIB :

Comparaison des émissions de CO2/habitant sur ces 5 pays Européens




		country	
population	mean	France	55353126
		Germany	78504409
		Italy	55443368
		Poland	34906480
		Spain	38326950



		country	
gdp	mean	France	1.490245e+12
		Germany	2.076479e+12
		Italy	1.305681e+12
		Poland	4.360179e+11
		Spain	7.574315e+11

Entre ces 5 pays, l'Allemagne apparaît comme émettant plus de CO2 par habitant que les 4 autres mais en baisse depuis 1980.




La Pologne, qui a un PIB plus faible, montre des émissions assez élevées par habitant avec une tendance à stagner et donc à dépasser les autres. Depuis 2000, ce pays ne semble pas arriver à baisser ses émissions de CO2/hab.

-> Dépendance au charbon, en cours d'abandon pour l'Allemagne, persistante pour la Pologne.

Comparaison des émissions de Méthane/habitant sur 5 pays Européens les plus proches de la France en Populations et PIB

Evolution des émissions de méthane/habitant entre 1950 et 2022




La pologne apparaît comme ayant émis beaucoup plus de méthane par habitant que les 4 autres pays, jusqu'à 1980, et en émet à peu près autant qu'eux aujourd'hui.

L'incidence est moindre si on tient compte de la durée de vie du méthane dans l'atmosphère = 12 ans contre 100 ans pour le CO₂, et plus de 100 ans pour le N₂O.

Comparaison des émissions d'oxyde Nitreux/ Habitant sur 5 pays Européens les plus proches de la France en Populations et PIB


Evolution des émissions d'oxyde nitreux entre 1950 et 2022



La France a été le pays le plus émetteur d'oxyde nitreux jusqu'en 2005.
 Depuis 2000, c'est la Pologne qui en émet le plus parmi ces 5 pays sans que cela semble en voie de baisser.
 Après avoir baissé en Espagne et en Italie, la tendance semble être à la stagnation.

France Allemagne Émissions de CO2 par Source en 2022

France et Allemagne - Émissions de CO2 par Source en 2022



France Allemagne Émissions de CO2 par Source en 2022


Ce graphique montre les différences entre ces deux pays en termes de distribution des émissions de CO2 et cible les sources sur lesquelles il faut travailler pour réduire leur impact sur l'environnement.

Pour la France, la dépendance au pétrole est élevée.

Pour l'Allemagne, bien que le charbon reste une source importante, la répartition entre le charbon, le pétrole et le gaz est plus équilibrée que ce que l'on aurait pu imaginer.

Corrélation entre Émissions de CO2 par source pour la France et l'Allemagne.

Corrélations des Émissions de CO2 par Source pour la France et l'Allemagne (1957-2022)



Forte corrélation négative entre les émissions de CO2 du charbon et du gaz dans les deux pays. Cela peut refléter des transitions énergétiques entre ces deux sources.

Les émissions de CO2 du pétrole et du ciment montrent une forte corrélation positive significative dans les deux pays. Cela indique que les augmentations des émissions de CO2 provenant du pétrole sont accompagnées d'augmentations des émissions de ciment.

Certaines corrélations entre les différentes sources d'émissions de CO2 sont modérées ou faibles. Cela montre que les relations entre les sources d'émissions de CO2 peuvent varier en fonction des politiques énergétiques et économiques spécifiques à chaque pays.

Les fortes corrélations négatives entre le charbon et le gaz pourraient indiquer des **opportunités pour faciliter la transition entre ces sources d'énergie.**

Les corrélations positives entre le pétrole et le ciment suggèrent que les politiques visant à **réduire les émissions de CO2 devraient peut-être cibler ces secteurs conjointement.**

Comprendre ces relations peut aider à **diversifier les sources d'énergie de manière stratégique** pour réduire les émissions de CO2 globales.

Rendu 2 : Rapport de Modélisation

Objectif : Modéliser l'évolution de la température mondiale par année

Datasets utilisés :


```
data_by_country = pd.read_csv('owid-co2-data.csv')  
temperature_data = pd.read_csv('GLB.Ts+dSST.csv')
```

1. MODÉLISATION 1

Variables explicatives		Variable cible
Année (Year) : Cela est indispensable pour lier les deux datasets		J-D (Annual mean) : Température mondiale moyenne annuelle
PIB (gdp) : Le produit intérieur brut d'un pays, qui peut influencer les émissions de gaz à effet de serre et la croissance économique.		
CO2 (co2) : Les émissions de dioxyde de carbone, un facteur majeur dans le réchauffement climatique.		
Population (population) : L'impact démographique sur les émissions.		
Emissions par secteur : Peut également être un facteur explicatif pertinent.	cement_co2	
	coal_co2	
	oil_co2	
	gas_co2	

methane : Emissions de méthane.	
nitrous_oxide : Emissions d'oxyde nitreux.	

Modèle de Régression : Régression Ridge



Observations :

Bonne tendance globale : La plupart des points suivent la ligne rouge, ce qui confirme un modèle performant.

Léger effet en escalier pour certaines valeurs négatives : On observe un regroupement de points pour des valeurs négatives de y_{test} , ce qui peut indiquer un léger biais ou une sous-estimation pour certaines plages de températures.

Dispersion pour les grandes valeurs : Pour les valeurs de y_{test} les plus élevées (vers 0.6 - 0.8), les points s'éloignent un peu de la ligne rouge, ce qui pourrait signifier que le modèle a plus de mal à prédire les températures extrêmes.

Résultats :

- Meilleur **alpha**: **0.1**

L'**alpha optimal 0.1** montre que la régularisation n'est pas trop forte, ce qui signifie que les variables explicatives ont encore un impact important sur les prédictions sans être trop pénalisées.

- Test **R²**: **0.8804921416714826**

Le modèle explique **88% de la variance** de la température mondiale par année, ce qui est **très bon**. Cela signifie que les variables explicatives capturent bien la tendance des températures mondiales.

- Test **MAE**: **0.09304220568860992**

En moyenne, l'erreur absolue sur la prédiction est d'environ **0.093°C**, ce qui est relativement faible.

- Test **RMSE**: **0.10568709640238379**

L'erreur quadratique moyenne est également faible, indiquant que les prédictions sont **précises et stables**.

- Train **R²**: **0.9027036687367949**

Légère différence avec Test R², ce qui est bon signe. Il n'y a pas de **surapprentissage majeur**, le modèle généralise bien.

2. MODÉLISATION 2

Préparation des données :

- On effectue un agrégat du fichier CO2 sur l'année et on obtient une ligne par année
- Jointure des deux fichiers sur la colonne année
- Limitation du jeu de données à post 1850 et avant le covid qui a engendré des données exceptionnelles
- Séparation des jeux de test et d'entraînement
- Remplacement des valeurs manquantes dans le fichier du CO2 par la médiane de la colonne: -> Vérification qu'il n'y a plus de valeurs nulles dans les jeux de données
- Dimensions de X_train : (2817, 9)
- Dimensions de X_test : (705, 9)

Modélisation de Régression Linéaire :


Score R² des jeux de données train et test:

R² des données train: **0.7934134654218292**

R² des données test: **0.7900733175207287**

Pas de surentraînement

Droite de régression et nuage de points sur le jeu de test




Evaluation des performance du modèle:

MSE: 0.03081106013211426

RMSE: 0.17553079539532163

-> Le modèle ne semble pas très bien adapté, on va essayer une régression polynomiale

Régression polynomiale second degré et nuage de points sur le jeu de test



Evaluation des performances du modèle :

R² sur les données de train: **1.0**

R² sur les données de test: **0.9150**

Pas de surentraînement

RMSE: **0.1116**

-> Le modèle de régression polynomiale semble mieux adapté que la régression linéaire.

3. MODÉLISATION 3

Analyse Historique (1880-2020) et **Projections Futures** (2025-2100).

Les Objectifs de la modélisation :

- **Évaluer plusieurs modèles de machine learning** pour modéliser les relations entre variables explicatives et anomalies climatiques ('J-D').
- **Projeter les tendances climatiques futures** (2025-2100) suivant 2 scénarios distincts:
 - **Scénario Optimiste : Réduction des émissions et transition énergétique durable** (source GIEC / SSP1-2.6) .
 - **Scénario pessimiste : Forte dépendance aux combustibles fossiles** (source GIEC / SSP5-8.5).

La Stratégie Adoptée :

Étapes du projet	Description
Collecte et Nettoyage des Données	Remplacement des valeurs manquantes par NaN, suppression des lignes incomplètes. Conversion des anomalies (J-D) en float.
Sélection des Variables	Variables sélectionnées : Année, PIB, CO2, population, émissions par secteur (ciment, charbon, pétrole, gaz), méthane, oxyde nitreux.
Fusion et Agrégation	Fusion des données climatiques et socio-économiques. Calcul des moyennes annuelles des émissions pour éviter les variations saisonnières.
Sélection des Variables Explicatives et Cible	Variables Explicatives (X) : Année, PIB, CO2, population, émissions de ciment, charbon, pétrole, gaz, méthane, oxyde nitreux. Variable Cible (y) : Anomalie de température ('J-D').

Normalisation et Partitionnement	Normalisation des données explicatives pour les mettre sur la même échelle. Séparation des données en 70 % entraînement / 30 % test.
Modélisation	Modèles comparés : Régression Linéaire, Forêts Aléatoires, Régression Ridge, Gradient Boosting, Réseau de Neurones.
Projections Futures	Simulations de deux scénarios : Optimiste (croissance faible) et Pessimiste (croissance élevée) .

Les Résultats des 5 différents Modèles :

Modèle	R ² (Test)	MAE (Test)	RMSE (Test)	MSE (Test)	Score Entraînement	Score de Test	Validation Croisée (R ²)
Régression Linéaire	0.9019	0.0946	0.1089	0.0119	0.8928	0.9019	0.8507
Forêts Aléatoires	0.9306	0.0722	0.0915	0.0084	0.9859	0.9306	0.8803
Régression Ridge	0.9197	0.0820	0.0984	0.0097	0.9242	0.9197	-
Gradient Boosting	0.9267	0.0738	0.0940	0.0088	0.9955	0.9267	-
Réseau de Neurones	0.9002	0.09021	0.1097	0.01204	0.8904	0.9003	-

- Le modèle de **Forêts Aléatoires** affichent la meilleure performance globale avec un **R² de test de 0.9306** et les erreurs (MAE, RMSE, MSE) les plus basses.

- **Gradient Boosting** vient très proche, offrant des résultats très similaires aux Forêts Aléatoires, avec un **R² de test de 0.9267** et également de faibles erreurs.

- **Régression Ridge et Régression Linéaire** ont des performances décentes avec des valeurs de **R² test respectivement de 0.9197 et 0.9019**, mais elles ont des erreurs un peu plus élevées par rapport aux modèles ci-dessus.

- Le **Réseau de Neurones**, bien qu'assez performant avec un **R² test de 0.9002**, semble avoir les erreurs les plus élevées parmi les modèles comparés ici, ce qui pourrait indiquer qu'il n'est pas la meilleure option dans notre cas précis.

-> Le modèle de Forêts Aléatoires est donc une “option solide” pour prédire les températures.

Ci dessous l' Analyse approfondie de ses performances :

R² de Test (0.9306) : Indique que le modèle explique **93,06 % de la variance des températures**, ce qui démontre une excellente précision dans les prédictions.

MAE (0.0722) : Erreur absolue moyenne très faible, ce qui signifie que **les prédictions du modèle s'écartent en moyenne de seulement 0,0722°C des valeurs réelles**. Cela garantit une grande fiabilité pour les applications où des écarts minimes sont nécessaires.

RMSE (0.0915) : Cette métrique met en lumière **une erreur moyenne très faible de 0,0915°C**, et le fait que le modèle gère efficacement les valeurs aberrantes et les écarts importants.

MSE (0.0084) : **La variance des erreurs est extrêmement basse**, ce qui reflète une précision constante et une stabilité dans les prédictions.

Validation Croisée R² (0.8803) : Indique **une capacité de généralisation robuste, avec une performance moyenne de 88,03 %** sur les ensembles de données de validation. Cela suggère que le modèle est bien adapté pour prédire sur des données qu'il n'a pas encore vues.

-> Utilisation de **GridSearchCV** pour optimiser les hyperparamètres en testant systématiquement différentes combinaisons :

Les scores moyens les plus élevés (0.880297) ont été obtenus avec **500 estimators** et une **profondeur maximale de 10**.

Meilleurs hyperparamètres trouvés : {'max_depth': 10, 'n_estimators': 500}

Toutes les combinaisons d'hyper paramètres testées et les scores correspondants :

	param_n_estimators	param_max_depth	mean_test_score	std_test_score
0	100	10	0.875602	0.083121
1	200	10	0.878940	0.079294
2	500	10	0.880297	0.078495
3	100	20	0.875633	0.083733
4	200	20	0.878762	0.080088
5	500	20	0.880159	0.078703
6	100	30	0.875633	0.083733
7	200	30	0.878762	0.080088

8	500	30	0.880159	0.078703
---	-----	----	----------	----------

Top 5 combinaisons d'hyperparamètres :

param_n_estimators	param_max_depth	mean_test_score	std_test_score
--------------------	-----------------	-----------------	----------------

2	500	10	0.880297	0.078495
---	-----	----	----------	----------


5	500	20	0.880159	0.078703
---	-----	----	----------	----------



8	500	30	0.880159	0.078703
---	-----	----	----------	----------



1	200	10	0.878940	0.079294
---	-----	----	----------	----------

4	200	20	0.878762	0.080088
---	-----	----	----------	----------

Représentations graphiques des modèles:








Le modèle des **Forêts Aléatoires** offre un bon compromis entre précision et robustesse, tandis que le **Gradient Boosting** pourrait être utile pour des données très complexes.

Comparaison des modèles sur un graphique :



Projections Futures (Stratégie et Résultats) :

- Définir une plage de prédictions (De 2025 à 2099 incluses) et envisager des hypothèses Crédibles pour les scénarios (Sources Giec)
- Calculer les projections annuelles pour chaque variable explicative en appliquant un taux de croissance constant basé sur les moyennes historiques.
- Générer un DataFrame contenant les projections pour les variables explicatives en appliquant les taux de croissance à leurs moyennes historiques.
- Normaliser les données futures en utilisant le même scaler que celui appliqué aux données historiques.
- Appliquer les modèles pour générer les prédictions sur les données normalisées des 2 scénarios optimiste et pessimiste.
- Combiner les prédictions de plusieurs modèles.
- Organiser les prédictions dans un DataFrame associant les années futures aux anomalies de température prévues.

Variable	Scénario Optimiste (SSP1-2.6)	Scénario Pessimiste (SSP5-8.5)
PIB	+2,5 %	+3,0 %
CO2 (émissions)	-2,0 %	+2,5 %
Population	+0,5 %	+1,0 %
Ciment CO2	+0,5 %	+2,0 %
Charbon CO2	-2,0 %	+1,5 %
Pétrole CO2	-2,0 %	+1,5 %
Gaz CO2	-2,0 %	+1,5 %
Méthane	+0,5 %	+1,5 %
Oxyde Nitreux	+0,5 %	+1,5 %

Le GIEC (Groupe d'experts intergouvernemental sur l'évolution du climat) élabore des scénarios socio-économiques pour analyser les trajectoires possibles du changement climatique.


Ces hypothèses sont clés pour modéliser les trajectoires des anomalies climatiques selon les scénarios SSP1-2.6 et SSP5-8.5.

Prédictions futures - Scénario Optimiste :

Year Predicted_Temperature_Anomaly

0 2025 0.295876

74 2099 1.318579 °C




Prédictions futures - Scénario Pessimiste :


Year Predicted_Temperature_Anomaly

0 2025 0.295876

74 2099 **3.268671 °C**



Juxtaposition des 2 modèles de Prédiction futures :



Une juxtaposition des deux trajectoires révèle **un écart de près de 2°C en 2099**, soulignant l'urgence d'agir pour éviter les impacts les plus graves.

Le Meilleur modèle :

- **Le modèle de forêts aléatoires** affichent les meilleures performances pour modéliser et prédire les anomalies climatiques.

L' Impact des Politiques Climatiques au travers des deux scénarios :

- Le **Scénario Optimiste** reste **sous la limite des 1,5°C (1,31 °C en 2099)**, démontrant les bénéfices des politiques climatiques ambitieuses et d' une transition énergétique durable.
- Le **Scénario Pessimiste dépasse 3,26°C en 2099**, illustrant les dangers de l' inaction climatique et la gravité de ces conséquences.

Conclusion

Nos différentes analyses confirment bien une forte corrélation entre les anomalies climatiques et les émissions liées aux activités humaines — en particulier le CO₂ et les émissions sectorielles (charbon, pétrole, gaz) — depuis la Révolution industrielle, et dans les pays qui l'ont initiée. Par ailleurs, les émissions de N₂O mériteraient une attention particulière, compte tenu de leur longue persistance dans l'environnement et du fait que tous les pays ne semblent pas les avoir réduites.

Les différents modèles d'analyse utilisés montrent bien que les choix politiques et économiques influencent de manière décisive les trajectoires climatiques futures.

Les résultats mettent en évidence une relation marquée entre l'augmentation des températures et les émissions de CO₂, avec des contributions significatives des secteurs énergétiques.

Les différents modèles montrent que des “politiques ambitieuses” peuvent limiter les réchauffements sous la limite critique fixée par l'Accord de Paris. Le modèle de Forêts Aléatoires montre la capacité à prédire ces impacts avec une précision élevée.

Les scénarios pessimistes illustrent un futur où l'inaction climatique engendrerait des effets catastrophiques sur les écosystèmes, les sociétés et les économies.

Les résultats sont cependant dépendants des hypothèses et des données historiques. Les incertitudes liées aux évolutions démographiques, technologiques ou aux politiques futures doivent bien entendu être prises en compte. L'exploration de données concernant les énergies renouvelables, l'intégration de données géographique et sectorielles sont des outils d'analyse pertinents qui pourraient affiner nos résultats et nous permettre de démontrer que l'augmentation des températures tend à ralentir au fur et à mesure de la mise en place de ces solutions.

"Le futur climatique que nous construisons aujourd'hui déterminera les vies de demain. Ensemble, nous avons le pouvoir de faire des choix qui préservent notre planète pour les générations futures."